

Predlog projektnog zadatka

Ognjen Čavić

Opis zadatka:

1. Napisati teorijski pregled *LSTM* (*Long Short-Term Memory*) modela, ciljne funkcije unakrsne entropije (*cross-entropy*) i *ADAM* metode optimizacije.
2. Implementirati sledeće funkcionalnosti nad postojećim *dumbgrad* alatom:
 - Proširen skup podržanih funkcija aktivacije implementacijom funkcija **sigmoid**, **ReLU**, **leaky ReLU**. Trenutna implementacija podržava samo funkciju **tanh**, što ograničava mogućnosti uvođenja nelinearnosti u model, time i njegovu sposobnost da prepozna obrascе.
 - Proširen skup podržanih ciljnih funkcija implementacijom funkcije unakrsne entropije i prosečne apsolutne greške.
 - Mehanizam regularizacije modela penalisanjem parametara korišćenjem L1 i L2 normi. Cilj je povećati otpornost modela na preterano prilagođavanje (**overfitting**) na trening skup podataka.
 - Paralelizovana obuka modela. Jedan od mogućih načina realizacije jeste podelom podataka za obuku na određen broj podskupova, potom na svakoj niti odvojeno obučiti model, na kraju ih kombinovati uzimanjem proseka.
 - *LSTM* model, kao i mogućnost kombinovanja slojeva obične neuronske mreže sa *LSTM* slojevima.
3. Pomoću implementiranih funkcionalnosti kreirati primitivan jezički model zasnovan na predviđanju sledećeg slova, po uzoru na: <https://github.com/karpathy/makemore>. Kao bazu koristiti <https://huggingface.co/datasets/jerteh/SrpELTeC>, što je zbirka starih srpskih knjiga i sadrži oko 5 miliona reči.
4. Napisati adekvatnu dokumentaciju za realizovan kod, kao i detaljno upustvo za upotrebu.

5. Napraviti *IPython Notebook (ipynb)* u kojem se demonstrira proces obuke i koriscenje modela.

Rezultat ovog rada je:

1. Dokument sa teorijskim pregledom *LSTM* modela, ciljne funkcije i metode optimizacije.
2. Funkcionalni kod na *Github*-u, kao i prateća dokumentacija i uputstvo za upotrebu.
3. Izveštaj u formi naučnog rada gde se opisuju rezultati u vidu tačnosti predviđanja fonema